

공통과제 보고서

한국어 학습 도우미

Korean Language Learning Assistant

AI Native Camp · 2026

1. 프로젝트 소개 / Project Description

1.1 프로젝트 배경

저는 터키 출신으로 현재 한국에서 인턴으로 일하고 있습니다. 한국어를 배우는 과정에서 "내가 직접 사용할 수 있는 학습 도구를 만들면 어떨까?"라는 아이디어에서 이 프로젝트를 시작했습니다.

한국어 학습자가 문법, 어휘, 표현에 대해 자유롭게 질문하면, 학습 자료(PDF)에서 관련 내용을 찾아 한국어 + 영어 + 터키어 3개 국어로 답변하는 RAG 기반 챗봇입니다.

1.2 아이템 속성

이름	한국어 학습 도우미 (Korean Language Learning Assistant)
목적	한국어 학습자를 위한 RAG 기반 대화형 학습 도구
대상 사용자	한국어를 배우는 외국인 (초급~중급)
지원 언어	한국어, English, Türkçe (3개 국어)
실행 환경	완전 로컬 실행 (API 키 불필요, 인터넷 불필요)

1.3 주요 기능

#	기능	설명
1	RAG 기반 질의응답	PDF 문서에서 관련 내용 검색 — hallucination 방지
2	스트리밍 응답	토큰 단위 실시간 출력
3	멀티턴 대화	세션 내 대화 기록 유지, 후속 질문에 이전 맥락 기억
4	3개 국어 지원	한국어 + 영어 + 터키어 동시 답변

2. 기술 선택 및 이유 / Tech Stack & Rationale

모든 구성요소는 완전 로컬 실행을 원칙으로 선택되었습니다. 비용 없이, API 키 없이, 프라이버시를 보장하며 동작합니다.

LLM	Ollama gemma3:4b	완전 로컬 실행, API 키 불필요, 비용 없음, 프라이버시 보장	Anthropic Claude (유료), Google Gemini (쿼터 제한)
Framework	LangChain	과제 요구사항 명시, RAG 구성 요소 제공, pipe 연산자로 직관적 체인 구성, LLM/벡터 교체 용이	-
Embeddings	HuggingFace all-MiniLM-L6-v2	무료, 로컬 실행, 384차원 고품질 임베딩, 다국어 지원 (한·영·터키)	OpenAI (유료), Anthropic (유료)
Vector DB	Chroma	로컬 실행, 간단한 설치, 디스크 영구 저장, LangChain 통합	FAISS (영구저장 추가 설정), OpenSearch (서버 구축 필요), Pinecone (유료)
Streaming	chain.stream()	LangChain 내장 기능, 동기/비동기 모두 지원, 체감 대기 시간 감소	-
Chat Hist.	RunnableWith MessageHistory	LangChain 공식 권장, session_id 기반 사용자별 관리 (한계: 인메모리)	DB 저장 (향후 확장 가능)
Doc Load	PyPDFLoader + RecursiveTextSplitter	페이지 단위 추출, 다단계 구분자로 의미 일관성 유지 chunk_size=1000, overlap=200(20%)	-

3. 시스템 아키텍처 / System Architecture

3.1 전체 데이터 흐름

1. 사용자 입력	사용자 질문 수신
2. app.py	메인 진입점, 입력 전달
3. rag_chain.py	RAG 체인 실행
4. Retriever	Chroma DB에서 관련 청크 검색
5. Prompt	MessagesPlaceholder + ChatPromptTemplate 구성
6. ChatOllama	로컬 LLM (gemma3:4b) 추론
7. StrOutputParser	문자열 파싱
8. 스트리밍 출력	토큰 단위 실시간 사용자 출력

3.2 프로젝트 구조

app.py	메인 진입점 — CLI 루프, 스트리밍 출력 처리
--------	-----------------------------

config.py	설정값 관리 — 모델명, 청크 크기, 경로 등
chains/rag_chain.py	RAG 체인 구성 — Retriever + Prompt + LLM + Parser
loaders/doc_loader.py	문서 로드 · 분할 · Chroma 저장
data/	학습 PDF 문서 보관 디렉토리

3.3 모듈형 구조 선택 이유

각 모듈은 단일 책임 원칙(SRP)을 따릅니다. LLM 교체, 벡터 저장소 변경, 문서 파이프라인 수정 시 다른 모듈을 수정하지 않아도 됩니다. 예를 들어 Chroma를 FAISS로 교체하더라도 app.py나 rag_chain.py는 변경이 필요 없습니다.

4. 테스트 결과 / Test Results

스트리밍

스트리밍	토큰 단위 실시간 출력 확인 응답당 9~16 chunks 생성 로컬 추론 소요 시간 약 10초
------	--

멀티턴 메모리

멀티턴 메모리	Turn 1: "How do I say hello in Korean?" → 주제 도입 Turn 2: "What about the informal version?" → 'hello' 언급 없이 안녕 답변 Turn 3: "How do I use it in a sentence?" → 이전 맥락 기억, 예문 제공
---------	---

RAG 정확도

RAG 정확도	학습 자료: 3개 PDF, 19페이지 생성된 청크: 26개 상위 3개 청크 — 관련 내용 정확 검색 확인
---------	--